

Grundlagen von Datenbanken

4. Übung: Algebraische Optimierung

November 2012



Algebraische Optimierung

Ziel

- Effiziente Ausführung eines algebraischen Ausdrucks
- Minimierung der Größe von Zwischenergebnissen
(das Endergebnis soll gleich bleiben!)

Algebraische Optimierung

Ziel

- Effiziente Ausführung eines algebraischen Ausdrucks
- Minimierung der Größe von Zwischenergebnissen
(das Endergebnis soll gleich bleiben!)

Voraussetzung

- Abschätzung der Größe von Zwischenergebnissen

Algebraische Optimierung

Ziel

- Effiziente Ausführung eines algebraischen Ausdrucks
- Minimierung der Größe von Zwischenergebnissen
(das Endergebnis soll gleich bleiben!)

Voraussetzung

- Abschätzung der Größe von Zwischenergebnissen

Verwendete Daten

- Anzahl der Tupel in einer Relation R : $Card(R)$
- Anzahl der unterschiedlichen Werte eines Attributes A_i : j_i
- Vertauschungsregeln für Operationen (siehe Skript)
z. B.: $\sigma_{P_1}(\sigma_{P_2}(R)) = \sigma_{P_1 \wedge P_2}(R)$

Algebraische Optimierung: Operatorenbaum

$\sigma_{\text{Nachname}=\text{"Müller"}}(\text{Studenten} \bowtie_{\text{Fach}=FID} \text{Fächer})$

Algebraische Optimierung: Operatorenbaum


$\sigma_{\text{Nachname}=\text{"Müller"}}(\text{Studenten} \bowtie_{\text{Fach}=FID} \text{Fächer})$

Annahme für das Beispiel

$\text{Card}(\text{Studenten}) = 40000$,

$\text{Card}(\text{Fächer}) = 80$

Anzahl unterschiedlicher Namen: 250
(bekannt aus dem Data-Dictionary)



Algebraische Optimierung: Operatorenbaum

$\sigma_{\text{Nachname}=\text{"Müller"}}(\text{Studenten} \bowtie_{\text{Fach}=FID} \text{Fächer})$

Annahme für das Beispiel

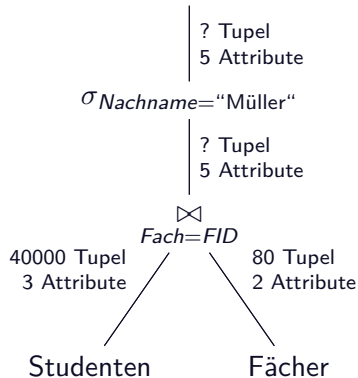
$\text{Card}(\text{Studenten}) = 40000$,

$\text{Card}(\text{Fächer}) = 80$

Anzahl unterschiedlicher Namen: 250
(bekannt aus dem Data-Dictionary)

Gesucht

Kardinalitäten beliebiger Operationen,
z. B.: $\text{Card}(\sigma_{\dots}(\text{Studenten} \bowtie \text{Fächer}))$



Selektivitätsfaktor

Motivation

- beschreibt Erwartungswert für die Anzahl der Tupel, die ein Prädikat erfüllen
- basiert auf statistischen Werten
- Annahmen
 - Gleichverteilung der Attributwerte eines Attributes
 - stochastische Unabhängigkeit verschiedener Attribute

Eigenschaften

- $0 \leq SF \leq 1$
- $Card(\sigma_P(R)) = SF(P) \cdot Card(R)$

Berechnung des Selektivitätsfaktors

Prädikate bezüglich eines Attributes

- $SF(A_i = x_i) = \frac{1}{j_i}$, falls Anzahl der Werte j_i für A_i bekannt
- $SF(A_i \geq x_i \wedge A_i \leq x_j) = \frac{x_j - x_i}{\max - \min}$, falls bekannt
- ... (siehe Skript)

Zusammengesetzte Prädikate

- $SF(p(A) \wedge p(B)) = SF(p(A)) \cdot SF(p(B))$
- $SF(p(A) \vee p(B)) = SF(p(A)) + SF(p(B)) - (SF(p(A)) \cdot SF(p(B)))$
- $SF(\neg p(A)) = 1 - SF(p(A))$

Kardinalitätsberechnung beim Verbund

Situation

in der Regel n:1-Verbund zwischen zwei Tabellen:

- TabelleA(PriA, A_1, \dots, A_n , Fremd)
- TabelleB(PriB, B_1, \dots, B_n)
- Referenz: TabelleA.Fremd \rightarrow TabelleB.PriB

Kardinalitätsberechnung beim Verbund

Situation

in der Regel n:1-Verbund zwischen zwei Tabellen:

- TabelleA(PriA, A_1, \dots, A_n , Fremd)
- TabelleB(PriB, B_1, \dots, B_n)
- Referenz: TabelleA.Fremd \rightarrow TabelleB.PriB

Verbund über alle Daten

$$Card(TabelleA \underset{Fremd=PriB}{\bowtie} TabelleB) = Card(TabelleA)$$

Kardinalitätsberechnung beim Verbund

Situation

in der Regel n:1-Verbund zwischen zwei Tabellen:

- TabelleA(PriA, A_1, \dots, A_n , Fremd)
- TabelleB(PriB, B_1, \dots, B_n)
- Referenz: TabelleA.Fremd \rightarrow TabelleB.PriB

Verbund über alle Daten


$$Card(TabelleA \underset{Fremd=PriB}{\bowtie} TabelleB) = Card(TabelleA)$$

Verbund über eine Teilmenge der Daten

$$\begin{aligned} & Card \left(\sigma_{P_A}(TabelleA) \underset{Fremd=PriB}{\bowtie} \sigma_{P_B}(TabelleB) \right) \\ &= SF(P_A) \cdot SF(P_B) \cdot Card(TabelleA) \end{aligned}$$

Kardinalitätsberechnung im Beispiel

$\sigma_{\text{Nachname}=\text{"Müller"}}(\text{Studenten} \bowtie_{\text{Fach=FID}} \text{Fächer})$




Kardinalitätsberechnung im Beispiel

$\sigma_{\text{Nachname}=\text{"Müller"}}(\text{Studenten} \bowtie_{\text{Fach}=FID} \text{Fächer})$

Berechnung des Verbundes

$\text{Card}(\text{Studenten} \bowtie_{\text{Fach}=FID} \text{Fächer})$
 $= \text{Card}(\text{Studenten}) = 40000$



Kardinalitätsberechnung im Beispiel

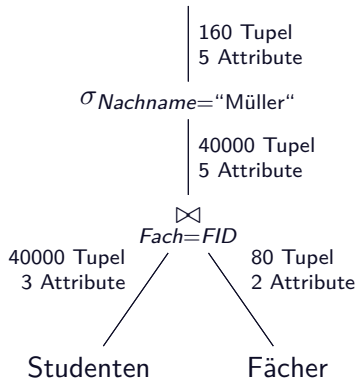
$$\sigma_{\text{Nachname}=\text{"Müller"}}(\text{Studenten} \bowtie_{\text{Fach}=FID} \text{Fächer})$$

Berechnung des Verbundes

$$\begin{aligned} \text{Card}(\text{Studenten} \bowtie_{\text{Fach}=FID} \text{Fächer}) \\ = \text{Card}(\text{Studenten}) = 40000 \end{aligned}$$

Berechnung der Selektion

$$\text{SF}(\text{Nachname} = \text{"Müller"}) = \frac{1}{250}$$



Heuristische Regeln zur Optimierung

- ① Führe Selektion so früh wie möglich aus
- ② Führe Projektion so früh wie möglich aus
- ③ (Verknüpfe Folgen von unären Operatoren (soweit möglich))
- ④ Fasse einfache Selektionen auf einer Relation zusammen
- ⑤ Verknüpfe bestimmte Selektionen mit einem vorausgehenden Kartesischen Produkt zu einem Verbund
- ⑥ (Berechne gemeinsame Teilbäume nur einmal)
- ⑦ Bestimme die Verbundreihenfolge so, dass die Anzahl und Größe der Zwischenobjekte minimiert wird
- ⑧ Verknüpfe bei Mengenoperationen immer zuerst die kleinsten Relationen

Optimierung des Beispiels

$\sigma_{\text{Nachname}=\text{"Müller"}}(\text{Studenten} \bowtie_{\text{Fach}=FID} \text{Fächer})$

