

Praktikum: Paralleles Programmieren

5. SIMD-Parallelisierung

Nathanael Hübbe

Wissenschaftliches Rechnen
Fachbereich Informatik
Universität Hamburg

10-5-2012

Flynn's Klassifikation

SISD	MISD
SIMD	MIMD

Einige SIMD-Implementationen

- Vektorprozessoren (Cray)
- MMX (Wiederverwendung der Fließkommaregister)
- SSE (8x 128 Bit)
- SSE2 (16x 128 Bit)
- SSE3 (horizontal Instructions)
- SSSE3 (2006: Ganzvektorshift/-rotate, allgemeine Permutation)
- AltiVec (32x 128 Bit)
- VSX (64x 128 Bit)

Vektorregister

- Seit SSE/AltiVec haben SIMD-Einheiten eigene Register.
- Breite der Register bestimmt den Grad an Parallelität.
 - SSE/AltiVec: 128 Bit, SSE2: 256 Bit
- Jeder Befehl verarbeitet Teile einer bestimmten Länge parallel.
 - z. B. AltiVec: 128 Bit = 16 Bytes, 8 Halfwords oder 4 Words
 - `add r3,r4,r5 $\hat{=}$ vaddsb/vaddsh/vaddsw v3,v4,v5`

Befehlsklassen

- Arithmetik

- Fixpunkt und Gleitkomma
- Grundrechenarten
- Zusätzlich horizontale Befehle z. B. vmsum
- Vergleiche produzieren bool-Vektoren

Befehlsklassen

■ Permutationen

- Meist Byteweise
- z. B. Shifts, rotates & splats
- Allgemeine Permutation:
Ein Register liefert Indizes (vperm)
- Selektion:
Die Bits eines Registers bestimmen, von welchem Register das entsprechende Ausgabebit kommt.

Befehlsklassen

- Cacheanweisungen
 - Vektoreinheiten sollen große Datenmengen schnell verarbeiten
 - \Rightarrow Bus wird noch leichter zum Flaschenhals
 - Daher: Spezielle Instruktionen um
 - Prefetching zu triggern
 - Daten als nicht mehr benötigt zu markieren

Beispiel: Eine Funktion, die den Index des Maximums in einem Array positiver 32-Bit Werte bestimmt.

■ Vorarbeiten

argmax:

```
srawi. r5,r4,2 #divide by four and compare against zero
mtctr r5
vspltisv v0,0 #=(0,0,0,0)
vspltisv v1,1 #=(1,1,1,1)
vspltisv v2,2 #=(2,2,2,2)
vspltisv v3,3 #=(3,3,3,3)
vmrghw v0,v0,v2 #=(0,2,0,2)
vmrghw v1,v1,v3 #=(1,3,1,3)
vmrghw v0,v0,v1 #=(0,1,2,3)
vspltisv v1,4 #=(4,4,4,4)
vspltisv v2,0 #clear it
vspltisv v3,0 #clear it
beq endloop #in case there is nothing to do
```


Beispiel: Die Hauptschleife

loop:

lvx v4,0,r3 #get four entries

addi r3,r3,16 #point to the next four

vcmpgtuw v5,v3,v4 #compare against the old max

vmaxuw v3,v3,v4 #update the max

vsel v2,v0,v2,v5 #remember the indices of the maxs

vadduws v0,v0,v1 #increment the indices

bdnz loop

endloop:

Beispiel: Die Nachbereitung

```
#Fuse the four results together
vsldoi v4,v3,v3,8 #rotate by two words
vsldoi v0,v2,v2,8
vcmpgtuw v5,v3,v4 #compare against the unshifted
vmaxuw v3,v3,v4 #update the max
vsel v2,v0,v2,v5 #remember the indices of the maxs
```

```
vsldoi v4,v3,v3,4 #rotate by one word
vsldoi v0,v2,v2,4
vcmpgtuw v5,v3,v4 #compare against the unshifted
vsel v2,v0,v2,v5 #remember the indices of the maxs
```

```
#Now all the words in v2 contain the result index,
#return it in r3.
stviewx v2,-4(sp)
lwz r3,-4(sp)
blr
```

Programmierung mit Compilerintrinsics

- Erlaubt die Verwendung von Vektoreinheiten aus Hochsprachen (also C) heraus.
- Aber:
 - 1 Assemblerbefehl → 1 Funktionsaufruf
 - Nicht Architekturunabhängig!
 - Vektordatentypen verkomplizieren die Programmierung
- ⇒ inline asm-Statements sind im allgemeinen lesbarer!

Bewertung

- Gut für rechenintensive Aufgaben (wenn die skalare Version den Bus nicht auslasten kann)
- Parallelität ohne Nebenläufigkeitsproblematiken
- Caching wird beeinflussbar
- Kein Vorteil, wenn der Bus ohnehin der Flaschenhals ist
 - Aber die Cache Anweisungen können dann helfen
- Parallelität durch Architektur begrenzt
- Feste Registerbreite bedeutet eine Menge Mehrarbeit
- Riesige Registerfiles verteuern Kontextwechsel